

MACHINE LEARNING ANALYTICS REPORT

넷플릭스 TOP10 장기 흥행 콘텐츠 특징 분석 및 예측 모델링 보고서

글로벌 넷플릭스 TOP10 주간 데이터를 기반으로 한 장기 생존 콘텐츠 분류 모델링 분석

분석 대상 데이터: Netflix Top 10 Weekly Dataset (2021.07.04 ~ 2022.01.16)

데이터 규모: 글로벌 1,160건 / 국가별 54,520건

적용 모델: 로지스틱 회귀 (Logistic Regression)

타겟 변수: 장기 흥행 여부 (**long_hit**: 4주 이상 TOP10 유지)

1. 모델링 목적

넷플릭스 글로벌 TOP10 차트에는 매주 수많은 신규 영화 및 TV 시리즈가 진입하지만, 대다수의 콘텐츠는 1~2주 내에 순위권 밖으로 밀려나며 소수의 작품만이 수개월 동안 차트에 잔류하며 막대한 누적 시청시간을 창출한다.

본 모델링의 핵심 목적은 “콘텐츠가 공개된 첫 주(Week 1)에 즉각 수집 가능한 초기 반응 지표만으로 해당 콘텐츠가 장기 흥행작이 될 수 있을지 조기에 판별하는 것”이다. 초기 예측 모델이 확립되면 스트리밍 플랫폼의 후속 마케팅 예산 배분, 서버 인프라 프로비저닝, 스폰오프 및 차기 시즌 제작 타당성 평가 등 주요 비즈니스 의사결정에 실질적인 데이터 가이드를 제공할 수 있다.

2. 장기 흥행 기준 (Target Variable Definition)

본 프로젝트에서는 콘텐츠의 장기 생존 여부를 정량적으로 분류하기 위해 타겟 변수 **long_hit**을 다음과 같이 이진 분류 (Binary Classification) 형태로 정의하였다.

구분	기준 조건 (글로벌 TOP10 누적 유지 주수)	Target Value (long_hit)	분류 정의
장기 흥행 (Positive)	글로벌 TOP10 차트 4주 이상 잔류	1	지속적인 파급력과 시청자 유입을 유지한 롱런 작품
단기 흥행 (Negative)	글로벌 TOP10 차트 4주 미만 (1~3주) 잔류	0	단기 화제성 후 빠르게 차트에서 퇴장한 일반 작품

기준 설정 관련 유의사항: 탐색적 데이터 분석(EDA) 결과 영화의 평균 유지 기간은 2.23주, TV는 3.24주(전체 중앙값 2.0주)로 나타났다. 이에 따라 평균과 중앙값을 상회하는 '4주 이상'을 장기 흥행의 운영상(Operational) 기준선으로 설정하였다. 이는 본 프로젝트 분석을 위한 기준이며, 플랫폼 및 업계 전체의 절대적 흥행 척도는 아니다.

3. 모델 선택 (Model Selection)

본 프로젝트에서는 분류 알고리즘으로 **로지스틱 회귀(Logistic Regression)**를 채택하였다. 복잡한 앙상블 또는 딥러닝 모델 대신 로지스틱 회귀를 선택한 주요 이유는 다음과 같다.

- **직관적인 확률 산출:** 각 콘텐츠가 장기 흥행(long_hit = 1)할 확률 값을 0과 1 사이의 연속적 수치로 직접 제공하여 비즈니스 위험도에 따른 유연한 평가가 가능하다.
- **명확한 계수 해석력 (Interpretability):** 각 독립변수가 흥행 성공 확률을 높이는 방향인지, 낮추는 방향인지를 회귀 계수의 부호와 크기를 통해 직접적이고 투명하게 파악할 수 있다.
- **경량성 및 과적합 제어:** 데이터 분석 입문 환경에서 기준선 모델(Baseline)로서 동작하기에 최적이며, 제한된 29주 관측치 데이터에서도 과적합 위험을 최소화할 수 있다.

4. 최종 투입 독립변수 (Feature Specification)

미래 시점의 데이터가 섞이지 않도록, 콘텐츠가 글로벌 차트에 최초로 진입한 첫 주 시점에 확인 가능한 4개의 핵심 변수만을 추출하여 모델에 투입하였다.

변수명	데이터 유형	변수 설명	추출 시점 및 의미
category	범주형 (Categorical)	콘텐츠의 형식 및 언어 구분 (Films English / Films Non-English / TV English / TV Non-English)	공개 첫 주 메타데이터
weekly_rank	수치형 (Integer)	글로벌 TOP10 차트 첫 진입 주차의 순위 (1위 ~ 10위)	첫 주 차트 진입 순위
weekly_hours_viewed	수치형 (Continuous)	글로벌 TOP10 차트 첫 진입 주차에 기록된 총 시청 시간 (Hours)	첫 주 글로벌 시청 화제성 규모
first_week_country_count	수치형 (Integer)	글로벌 차트 첫 진입 주차에 국가별 TOP10 차트에 동시 진입한 국가 수	첫 주 글로벌 국가 확산 속도 및 범위

5. 데이터 누수(Data Leakage) 발견 및 수정 과정

※ 핵심 학습 포인트: 미래 정보 유입 차단 및 피쳐 엔지니어링 정정

초기 분석 단계에서는 콘텐츠가 29주 관측 기간 전체 동안 TOP10에 1회라도 진입한 누적 국가 수인 country_count를 변수로 사용하고자 하였다. 그러나 면밀한 분석 검토 결과, 전체 기간 누적 국가 수는 **"콘텐츠가 오랜 기간 살아남았기 때문에 점진적으로 여러 국가로 확산된 결과"**가 반영된 지표임을 파악하였다.

즉, country_count를 첫 주 시점 예측 모델에 투입할 경우 미래의 누적 결과가 입력값으로 사전에 유입되는 전형적인 **데이터 누수(Data Leakage / Lookahead Bias)**가 발생하게 된다. 이는 학습 시 과도하게 높은 성능을 유발하지만, 실제 서비스 운영 환경에서는 첫 주 시점에 알 수 없는 정보이므로 모델이 무용지물이 된다.

이에 따라 최종 모델에서는 전체 누적 country_count를 완전히 배제하고, 글로벌 첫 진입 주차와 동일한 주에 개별 국가 TOP10에 진입한 순수 국가 수만을 집계한 **first_week_country_count**로 정정하여 재구축하였다.

6. 최종 로지스틱 회귀 모델 성능 결과 (Default Threshold: 0.50)

학습 데이터와 테스트 데이터 분할 후 기본 결정 임계값(Threshold = 0.50) 환경에서 산출된 최종 모델 성능 평가지표는 다음과 같다.

ROC-AUC	ACCURACY	PRECISION	RECALL	F1 SCORE
0.701	0.818	0.750	0.300	0.429
종합 판별력 지표	정확도 (81.8%)	정밀도 (75.0%)	재현율 (30.0%)	조화 평균

평가 지표	측정 수치	지표의 실무적 정의 및 해석
ROC-AUC	0.701	장기 흥행작과 단기 흥행작을 전반적으로 무작위 추천보다 유의미하게 구별해내는 판별 역량
Accuracy (정확도)	0.818	전체 콘텐츠 중 장기/단기 여부를 올바르게 맞힌 전체 비율 (81.8%)
Precision (정밀도)	0.750	모델이 "장기 흥행(1)"으로 예측한 작품 중 실제 장기 흥행한 비율 (75.0% - 신뢰도 높음)
Recall (재현율)	0.300	실제 장기 흥행한 전체 작품 중 모델이 감지해낸 비율 (30.0% - 다수 놓침)
F1 Score	0.429	정밀도(0.750)와 재현율(0.300)의 불균형을 고려한 조화 평균 수치

결과 종합 해석: 기본 모델은 정밀도(Precision)가 0.750으로 매우 높아, "장기 흥행작이라고 지목한 콘텐츠는 4건 중 3건 꼴로 실제 장기 흥행에 성공"하는 높은 신뢰성을 보였다. 그러나 재현율(Recall)이 0.300에 불과하여 **실제 장기 흥행에 성공한 대다수 콘텐츠(70%)를 단기 콘텐츠로 오판하여 포착하지 못하는 한계**가 존재한다.

7. 분류 임계값(Threshold) 조정 및 Trade-off 분석

실제 플랫폼 비즈니스에서는 잠재적인 대형 흥행작을 놓치는 비용(False Negative)이 잘못 예측하는 비용(False Positive)보다 클 수 있다. 이에 따라 장기 흥행 후보군을 보다 공격적으로 발굴하기 위해 결정 임계값을 0.50에서 0.35로 하향 조정하여 비교 분석하였다.

평가 지표	기본 모델 (Threshold = 0.50)	조정 모델 (Threshold = 0.35)	변화량 및 비즈니스 영향
Recall (재현율)	0.300	0.450	+0.150 (50% 향상) → 실제 흥행작 감지율 대폭 확대
Precision (정밀도)	0.750	0.500	-0.250 감소 → 가짜 흥행작 오판(FP) 발생 증가
Accuracy (정확도)	0.818	0.773	-0.045 소폭 감소 (77.3% 유지)
F1 Score	0.429	0.474	+0.045 상승 → 정밀도·재현율 균형 개선

Precision-Recall Trade-off 전략적 시사점: 임계값을 0.35로 낮추면 실제 장기 흥행작을 놓치지 않고 찾아내는 비율(Recall)이 30%에서 45%로 크게 상승한다. 반면, 모델이 흥행 후보로 지목한 작품 중 절반은 단기 흥행에 그치게 되므로(Precision 50%), **"마케팅 자원을 더 많은 잠재 후보에 분산 투자하되 후보군 탐색 범위를 넓히고자 할 때"** 0.35 임계값 채택이 유효한 전략이 된다.

8. 모델 내부 변수 관계 및 방향성 해석

로지스틱 회귀 계수를 통해 첫 주 투입 변수들이 장기 흥행 확률에 미친 상관적 방향성을 분석하였다.

변수 항목	모델 내부 작용 방향	분석적 맥락 및 세부 설명
TV (Non-English)	양(+)의 방향 (확률 증가)	오징어 게임, 갯마을 차차차 등 비영어권 TV 시리즈는 두터운 팬덤과 주차별 시청 지속력으로 장기 흥행 확률이 가장 높게 형성됨
first_week_country_count	양(+)의 방향 (확률 증가)	공개 첫 주에 다수 국가의 차트에 동시 안착할수록 글로벌 롱런 콘텐츠로 발전할 가능성이 유의미하게 증가함
weekly_hours_viewed	양(+)의 방향 (확률 증가)	첫 주 글로벌 시청시간 볼륨이 클수록 장기 흥행으로 이어지는 긍정적 기여도가 나타남
weekly_rank	음(-)의 방향 (확률 감소)	순위 숫자가 커질수록(예: 8~10위 하위권 진입) 장기 흥행 가능성이 하락하며, 1~3위 상위권 진입이 흥행에 유리하게 작용함
Films (English)	상대적 음(-)의 방향	영어권 영화는 공개 직후 단기 소비 성향이 강하여 TV 시리즈 대비 장기 차트 잔류 가능성이 상대적으로 낮게 나타남

★ 주의사항 (비인과성 원칙): 상기 변수들의 방향성은 회귀 모델 내부에서 도출된 통계적 연관성(Association)일 뿐이며, 특정 속성이 장기 흥행을 직접적으로 유발했다는 **인과관계(Causality)로 해석되어서는 안 된다.**

9. 모델링 한계점 (Limitations)

- **관측 기간의 제약 (29주):** 2021년 7월부터 2022년 1월까지 약 29주간의 한정된 기간만 포함되어, 수집 종료 시점에 차트에 진입해 있던 작품들의 최종 수명이 절단(Right-censored)되는 한계가 존재한다.
- **콘텐츠 메타데이터 부재:** 장르(스릴러, 로맨스 등), 제작비 규모, 주연 배우 인지도, 글로벌 사전 마케팅 집행비 등 실제 흥행을 결정하는 핵심 질적 정보가 데이터셋에 결여되어 있다.
- **장기 흥행 기준의 임의성:** 4주라는 기준은 탐색적 평균치에 근거한 실무적 기준선으로, 3주 또는 5주 등 기준값 변경에 따른 민감도 검증이 요구된다.
- **낮은 재현율(Recall = 0.30):** 첫 주 정보만으로는 입소문(워드오브마우스)으로 서서히 역주행하는 '슬리퍼 히트(Sleeper Hit)' 콘텐츠를 감지해내지 못하고 대거 누락하였다.
- **인과관계 추론 불가:** 관측 데이터에 기반한 상관관계 모델이므로 외생적 요인 통제 없이 인과적 처치 효과를 평가할 수 없다.

10. 향후 분석 및 모델 개선 방향 (Future Work)

- **다양한 머신러닝 알고리즘 비교:** 비선형적 상호작용과 변수 간 복잡한 관계를 학습할 수 있는 Random Forest, XGBoost, LightGBM 모델과의 벤치마킹 수행.
- **시계열 궤적 데이터 결합:** 첫 1주 단일 시점뿐 아니라 공개 후 2~3주 차의 시청시간 감쇄율(Drop-off Rate) 및 순위 유지 탄력성을 추가 피처로 모델링.
- **외부 데이터 확장:** IMDb/로튼토마토 평점, 소셜 미디어 버즈량, 제작사 및 감독 메타데이터를 외부 API를 통해 연계 수집하여 설명력 강화.

11. 프로젝트 최종 결론

**“첫 주 정보만으로 장기 흥행을 완벽하게 예측할 수는 없었지만,
초기 순위 · 시청시간 · 국가 확산 범위에서 장기 흥행과 관련된 유의미한 신호를 확인할 수 있었다.”**

ROC-AUC 0.701 및 정밀도 0.750 달성 | 초기 글로벌 확산 속도(first_week_country_count)가 핵심 판별 변수로 확인됨

본 프로젝트는 넷플릭스 주간 TOP10 데이터를 활용해 데이터 누수를 성공적으로 제어하고, 초기 지표 기반의 장기 흥행 예측 타당성을 입증하였다. 비록 첫 주만으로 모든 장기 생존작을 완벽히 식별할 수는 없었으나, **첫 진입 순위(weekly_rank), 첫 주 시청시간(weekly_hours_viewed), 첫 주 진입 국가 수(first_week_country_count)**라는 3대 초기 지표가 롱런 콘텐츠 조기 선별에 유용한 비즈니스 지표임을 통계적으로 규명하였다.

본 보고서는 프로젝트 제출용 머신러닝 모델링 결과 요약본이며, 원본 Colab 노트북의 데이터 전처리, 누수 제거, 로지스틱 회귀 모델링 파이프라인의 실제 산출 수치만을 근거로 작성되었습니다.